week2 10/23-10/29 总结

一、主要任务

任务产出

- 聚焦网络信贷违约预测任务，开展风控数据集 EDA 与特征工程工作，围绕贷前场景梳理特征构造、筛选、校验流程。
    - preprogressingupgrade_ipynb
    - featureengineering.ipynb
- 搭建 XGBoost 违约预测模型，完成基线；梳理树模型在信贷风控中的使用要点。
    - XGBOOST.ipynb
- 使用AI工具延续XGBOOST处理思路，完成逻辑回归、随机森林模型代码。
    - Regression.ipynb
    - RandomForest.ipynb
- 对比三个模型，比较AUC-ROC、F1等指标，确定XGBOOST为后续调优模型

实验报告

实验思路

本实验以借款人是否违约为预测目标，结合此前关于缺失值检查、类型转换和内存优化的讨论，采用“特征工程—分层划分—XGBoost建模—多指标评价”的技术路线，利用借款人的偿债压力、信用历史和账户结构识别违约风险。

实验过程

1. 特征构建：基于80万条样本，构造年化贷款收入比、循环余额收入比、开放账户占比、信用历史年限及FICO均值等特征
2. 特征选择：处理异常比值并删除冗余字段。

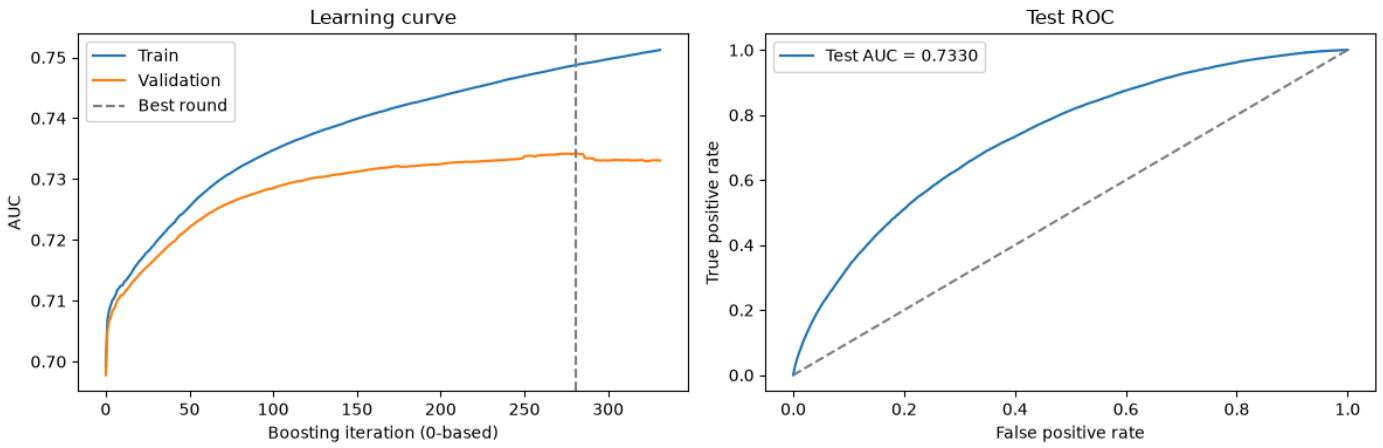
3. 样本划分：按照65%、15%、20%分层划分训练集、验证集和测试集。
4. 聚合特征：进一步构造类别分组统计特征，是由香农熵、最大最小值、分位数、均值等构造
5. 特征编码：结合有序编码、独热编码和五折交叉拟合目标编码，形成335个输入特征
6. 参数设置：预处理仅在训练集拟合，数据转为float32。
    1. 采用直方图算法，主要是为提高大样本、多特征条件下的训练效率；
    2. 树深设为5，旨在兼顾非线性关系学习与过拟合控制；
    3. 学习率设为0.05，使模型通过小幅更新逐步学习，并配合最多1000轮提供充分的迭代空间。
    4. 以验证集AUC作为早停依据，连续50轮未提升即停止，避免无效训练。
7. 特征排序：使用最佳轮次模型的 gain排序，展示前 20 个特征

实验结果

测试集AUC为0.7330、KS为0.3410。

阈值为0.5时，精确率为59.32%、召回率为9.55%、F1为0.1645。

模型具有一定风险区分能力，但违约漏判较多。后续可在验证集上调整阈值，并尝试类别加权，改善违约识别效果。



```python
importance = (
    pd.Series(model.get_score(importance_type="gain"), name="gain")
    .reindex(X_train.columns, fill_value=0)
    .sort_values(ascending=False)
    .rename_axis("feature")
    .to_frame()
)
top_features = importance.head(20)
top_feature_text = "、".join(top_features.index[:5])
display(Markdown(markdown_table(top_features)))
display(Markdown(f"**排序结果：** 按平均分裂增益，前五个特征为 {top_feature_text}。"))
figure, axis = plt.subplots(figsize=(9, 7))
top_features.sort_values("gain").plot.barh(ax=axis, legend=False)
axis.set(xlabel="Average gain", ylabel="", title="Top 20 feature importance")
figure.tight_layout()
plt.show()
```

18] Python

feature	gain
grade	2061.0439
subGrade_interestRate_max	1539.9229
subGrade	1410.3063
subGrade_loanAmnt_median	412.5717
term	164.2056
homeOwnership_loanAmnt_median	140.1037
homeOwnership_annualIncome_max	101.7051
homeOwnership_revolBal_median	96.4545
subGrade_dti_median	93.8966
homeOwnership_revolUtil_median	93.5369
verificationStatus_installment_max	93.1478

二、思考沉淀

EDA

- 数据缺失概率较大，尝试和时间匹配。例如，早期未建立相应的数据收集方式导致数据缺失。
- 一开始就应该划分数据类型，方便后面重复调用
  - 离散型
    - 类别
      - 低基数
      - 高基数
      - 顺序
    - 时间

    - 连续型
        - 连续
        - 计数
- 始终将目标和变量整合起来，初步筛查特征
- 为了观察分布，可以先在EDA把分箱做好
    - 离散型：
        - 顺序、低基数-柱状图
        - 高基数-kde
    - 连续性
        - 连续-等频分箱
        - 计数-线图

特征工程

- 创建特征：着重考察EDA
    - 一维交叉：类别×连续
    - 二维交叉：香农熵、权重
    - 聚合特征：分位数、最大最小值、中位数、平均值
    - 顺着业务逻辑，自己构造特征
- 特征选择：删除完全重复、已经过简单数学处理的变量
- 划分样本：对样本集的划分有id匹配和时间两种方式，金融场景下，选择优先规避时间泄露。
- 特征编码
    - 低基数：独热编码
    - 高基数：目标编码+k折平滑
    - 顺序：map映射
- 更多特殊的特征处理方式，应该放在模型之中再构建。比如均值化，不适合树模型，只放在逻辑回归中即可。先不统一处理。
- 样本检查与声明

XGBOOST

- 参数：使用直方图算法，树深度 5、学习率 0.05，最多训练 1,000 轮

- 早停：验证集 AUC 连续 50 轮未提升时停止。预测和特征重要性使用最佳轮次对应的模型。
- 特征重要性：按不纯度降序排序得到钱20个最重要的特征

卡点与下一步计划

1. 模型基础认知不够，包括适配数据类型、防止过拟合的方式、python代码实现，计划利用空余时间学习sklearn官方学习手册，并利用AI实现代码撰写
2. 特征选择部分目前未使用PCA和MI等算法，后续继续优