模型优化报告

XGBoost优化

第一轮优化：规范时间划分，补充匿名聚合信息。

- 按完整放款月份固定训练、验证和测试窗口，避免不同试验使用不同样本。
- 对匿名字段n0—n14生成均值、波动、非零数量和缺失数量等聚合特征，补充客户信息的统计描述。
- 完成20次参数搜索，每次采用5折时间验证；最终保留90个特征，按验证集结果选择模型。

第二轮优化：补充业务信息，检验是否有额外价值。

- 根据业务信息新增16项候选特征
- 完成50次搜索，同时比较沿用基线参数、沿用第一轮最优参数及重新搜索三种方案。
- 最终仍保留90个特征，其中新增候选仅有两项入模：

新增入模特征	计算方式	业务含义
合计偿债收入比（total_dti）	dti / 100 + installment × 12 / annualIncome	将已有债务与新增贷款年供放在统一口径下，描述整体偿债压力
全周期还款收入比（total_payment_incom…	installment × term × 12 / annualIncome	描述整笔贷款全部分期还款额相对一年收入的规模，不等同年度还款压力

一、样本划分

初始样本按照年份排序，优化后使用月份排序

样本	样本数	违约率	开始日期	结束日期
训练集	558371	0.1865	2007-06-01	2016-03-01
验证集	161731	0.2445	2016-04-01	2017-06-01
测试集	79898	0.1993	2017-07-01	2018-12-01

二、贝叶斯搜索范围与最佳参数

随机种子42，模型线程4，tree_method=hist，分类阈值0.5。使用Optuna TPE，前5次随机启动，以训练期五折平均ROC-AUC最大化为目标，不使用验证集或测试集早停。其中，learning_rate、reg_alpha、reg_lambda采用对数采样。
第一轮20次搜索，第二轮50次搜索。

参数	搜索范围	原基线	第一轮最优	第二轮最优
n_estimators	(100, 1000)	1000.000000	426.000000	304.000000
max_depth	(3, 8)	5.000000	6.000000	4.000000
learning_rate	(0.01, 0.15)	0.050000	0.012597	0.015389
min_child_weight	(1, 20)	5.000000	20.000000	17.000000
subsample	(0.6, 1.0)	0.800000	0.842194	0.703982
colsample_bytree	(0.6, 1.0)	0.800000	0.807530	0.616551
reg_alpha	(1e-08, 10.0)	0.000000	0.000000	0.000002
reg_lambda	(0.001, 10.0)	1.000000	0.113688	0.014893

三、时间交叉验证

每折仅用训练月份重新拟合缺失处理、分组统计、编码、IV和共线性筛选，随后转换验证月份。
目标编码内部5折交叉拟合与模型时间交叉验证分开执行。折内目标为AUC的算术平均，CV标准差为样本标准差。目标编码的内部五折交叉拟合与外层时间验证分开执行。

折	训练开始	训练结束	验证开始	验证结束	训练样本数	验证样本数	特征数
1	2007-06-01	2009-02-01	2009-03-01	2010-07-01	1369	5956	144
2	2007-06-01	2010-07-01	2010-08-01	2011-12-01	7325	16305	123
3	2007-06-01	2011-12-01	2012-01-01	2013-05-01	23630	57034	83
4	2007-06-01	2013-05-01	2013-06-01	2014-10-01	80664	168570	91
5	2007-06-01	2014-10-01	2014-11-01	2016-03-01	249234	309137	92

模型	CV平均AUC	CV标准差
第一轮_基线	0.632110	0.050538
第一轮_调优	0.666948	0.046655
第二轮_基线参数	0.631229	0.049486

模型	CV平均AUC	CV标准差
第二轮_上轮最优参数	0.669478	0.045464
第二轮_重新调优	0.671606	0.043963

四、新增特征

特征	公式	业务解释
new_installment_ratio	installment * 12 / annualIncome	新增贷款年供收入比
total_dti	**dti / 100 + new_installment_ratio**	**新增贷款后合计偿债压力**
loan_to_income	loanAmnt / annualIncome	本金收入比；不同于原按期限年化的比率
total_payment_income	installment *term* 12 / annualIncome	term为年，换算月数后的全周期还款收入比
revol_income	revolBal / annualIncome	循环余额收入比
util_high_flag	revolUtil > 70	循环额度高占用
util_mid_flag	30 < revolUtil <= 70	循环额度中等占用
open_acc_ratio	openAcc / totalAcc	在用账户占比
closed_acc	totalAcc - openAcc	关闭账户数，负数按原流程设为缺失
delinq_per_acc	delinquency_2years / (totalAcc + 1)	近两年逾期密度
has_pub_rec	pubRec > 0	公共负面记录标记
uncleared_negative	pubRec - pubRecBankruptcies	仅为记录数量差，不能识别污点是否已清除
fico_score	(ficoRangeLow + ficoRangeHigh) / 2	FICO区间中点
fico_low_flag	ficoRange_mean < 660	低FICO标记
credit_age_month	12 * (issue_year - first_credit_year) + issue_month - first_credit_month	精确信用账龄月数，不等同原年份差
new_credit_flag	credit_age_month < 24	信用账龄不足24个月
short_emp_flag	employmentLength < 2	使用清洗后就业年限，不使用岗位编码
term_int_burden	term * interestRate	年数乘百分数利率的交互项，不是实际总利息
high_install_flag	installment / annualIncome > 0.05	单月月供与年收入之比超阈值
joint_app_flag	待确认applicationType编码	不生成标记，保留原申请类型
debt_consolidation_flag	待确认purpose编码	不生成标记，保留原用途
n_valid_count	**count(n0..n14 > 0)**	**替换anonymous_nonzero_count；当前数据无负数**
n_missing_count	count(isna(n0..n14))	替换anonymous_missing_count，填补前计数
n_missing_flag	n_missing_count >= 3	匿名字段多项缺失，填补前生成

五、结果

两轮优化完善了客户偿债压力的刻画，保留的两项新特征，分别描述“原有债务加新增年供对收入的压力"和“整笔贷款全部分期还款额相对一年收入的规模”。

风险覆盖略有扩大，也增加了误标。 相比第一轮调优模型，第二轮最终模型多识别68名违约客户，同时多误标62名正常客户。

第一轮重点建立规范的优化与对比流程；第二轮重点补充业务特征、检验其增量价值。

模型	AUC	KS	PR-AUC	Precision	Recall	F1	AUC差_相对上轮基线	AUC差_相对上轮调优
第一轮_基线	0.722006	0.327004	0.379251	0.509265	0.096634	0.162445	0.000000	0.002216
第一轮_调优	0.719789	0.326345	0.375578	0.530378	0.066872	0.118769	-0.002216	0.000000
第二轮_基线参数	0.718260	0.319597	0.372543	0.496952	0.117732	0.190365	-0.003746	-0.001529
第二轮_上轮最优参数	0.719774	0.325730	0.375461	0.529935	0.071142	0.125443	-0.002232	-0.000015
第二轮_重新调优	0.715341	0.317034	0.369131	0.534145	0.049604	0.090779	-0.006665	-0.004449

最终选定模型混淆矩阵：

实际类别	预测正常	预测违约
正常	62967	1005
违约	14793	1133