模型对比报告

Model Comparison：逻辑回归、XGBoost 与随机森林

1. 实验设置

数据与划分

三个模型共用同一批 93 个特征，包括原始数值、业务衍生和分组统计等特征。

样本按放款年份排序，再按 70% / 20% / 10% 划分训练、验证和测试集

样本	样本数	占比	违约率
训练集	560,000	70%	19.01%
验证集	160,000	20%	23.14%
测试集	80,000	10%	20.16%
合计	800,000	100%	19.95%

模型与参数

LogitRegression，默认优化器，C=1.0，最多迭代1,000次。只训练一次，不搜索参数。

XGBoost 最多训练 1,000 轮，验证集 AUC 连续 50 轮没有提升就停止，本次最佳轮次为356。

随机森林最多100棵树，最深10层，最小叶子节点的样本不少于20个样本。

模型	特征处理	主要参数
逻辑回归	用训练集的中位数填补缺失，再标准化	L2 正则，C=1.0，solver=lbfgs，max_iter=1000
XGBoost	直接使用保存的特征，由模型处理缺失值	max_depth=5，min_child_weight=5，学习率=0.05，subsample=0.8，colsample_bytree=0.8，tree_method=hist
随机森林	用训练集的中位数填补缺失，不标准化	n_estimators=100，max_depth=10，min_samples_leaf=20

2. 指标汇总表

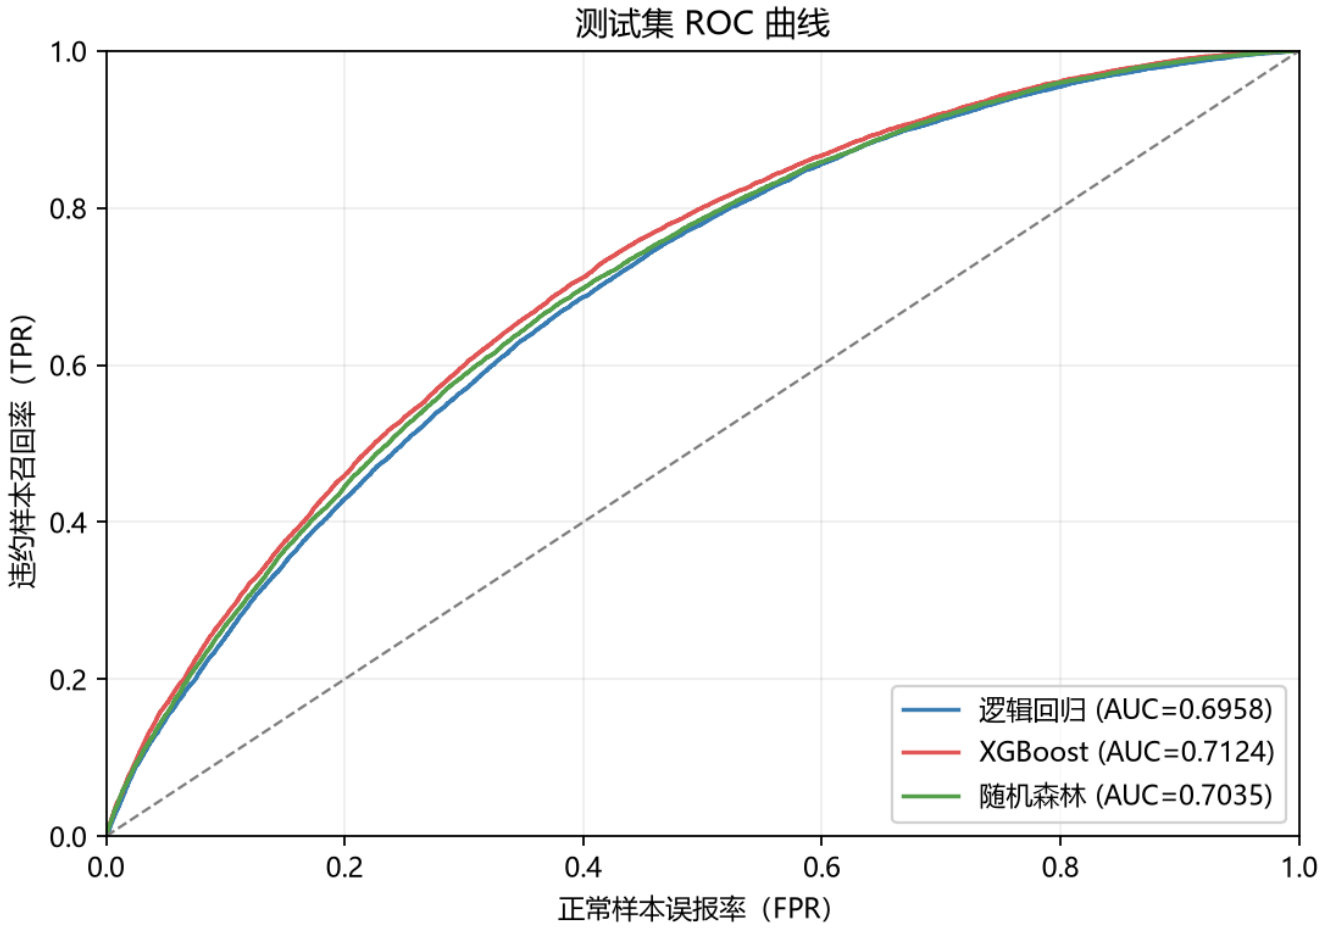
模型	训练 AUC	验证 AUC	测试 AUC	测试 KS	PSI：训练→验证	PSI：训练→测试
逻辑回归	0.7164	0.7064	0.6958	0.2870	0.0073	0.0034
XGBoost	**0.7378**	**0.7158**	**0.7124**	**0.3147**	**0.0058**	**0.0031**
随机森林	0.7282	0.7071	0.7035	0.2990	0.0071	0.0077

- **AUC** 看整体风险排序能力，越高越好；
- **KS** 看正常与违约样本能拉开多大差距，也是越高越好；
- **PSI** 看预测概率分布有没有变化，越小表示分布越接近。
  - 这里以各模型训练集预测概率的十分位点固定分档，再比较验证、测试集的各档占比；零占比用 0.000001 兜底。
- XGBoost 在验证集和测试集的 AUC 都最高。测试 AUC 比随机森林高 **0.0090**，比逻辑回归高 **0.0166**；测试 KS 也最高。

3. 图表：ROC、KS 曲线、分档坏账

以下图表均基于同一份 80,000 条测试样本。

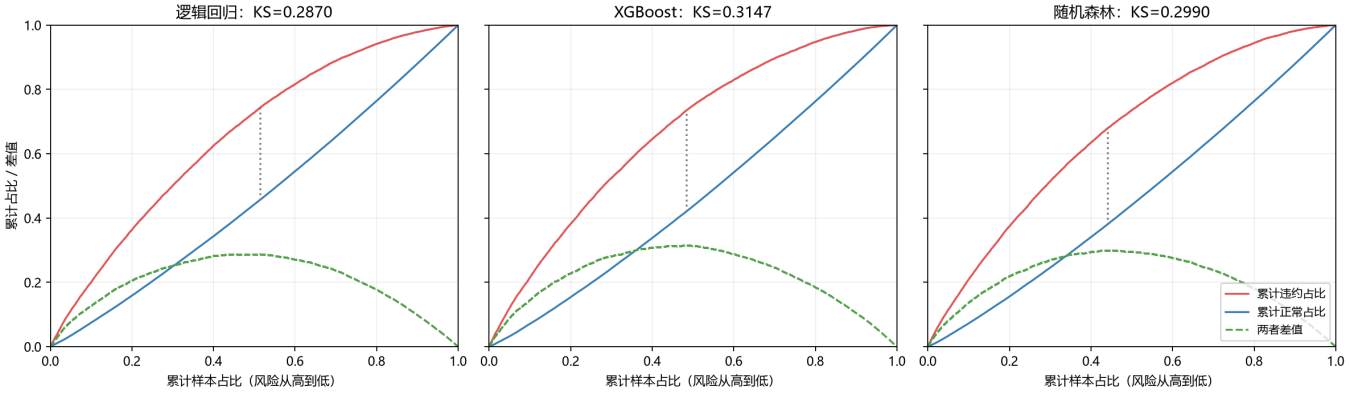
3.1 ROC 曲线



曲线越靠左上角越好，表示在相同误报率下能识别更多违约客户。

XGBoost 的整体排序表现最好，随机森林其次，逻辑回归略低。

3.2 KS 曲线



横轴按预测风险从高到低累计样本。红、蓝线分别是已覆盖违约样本、正常样本占各自总数的比例，两条线的最大差值就是 KS。

XGBoost 的 KS 为 **0.3147**，区分度最好。

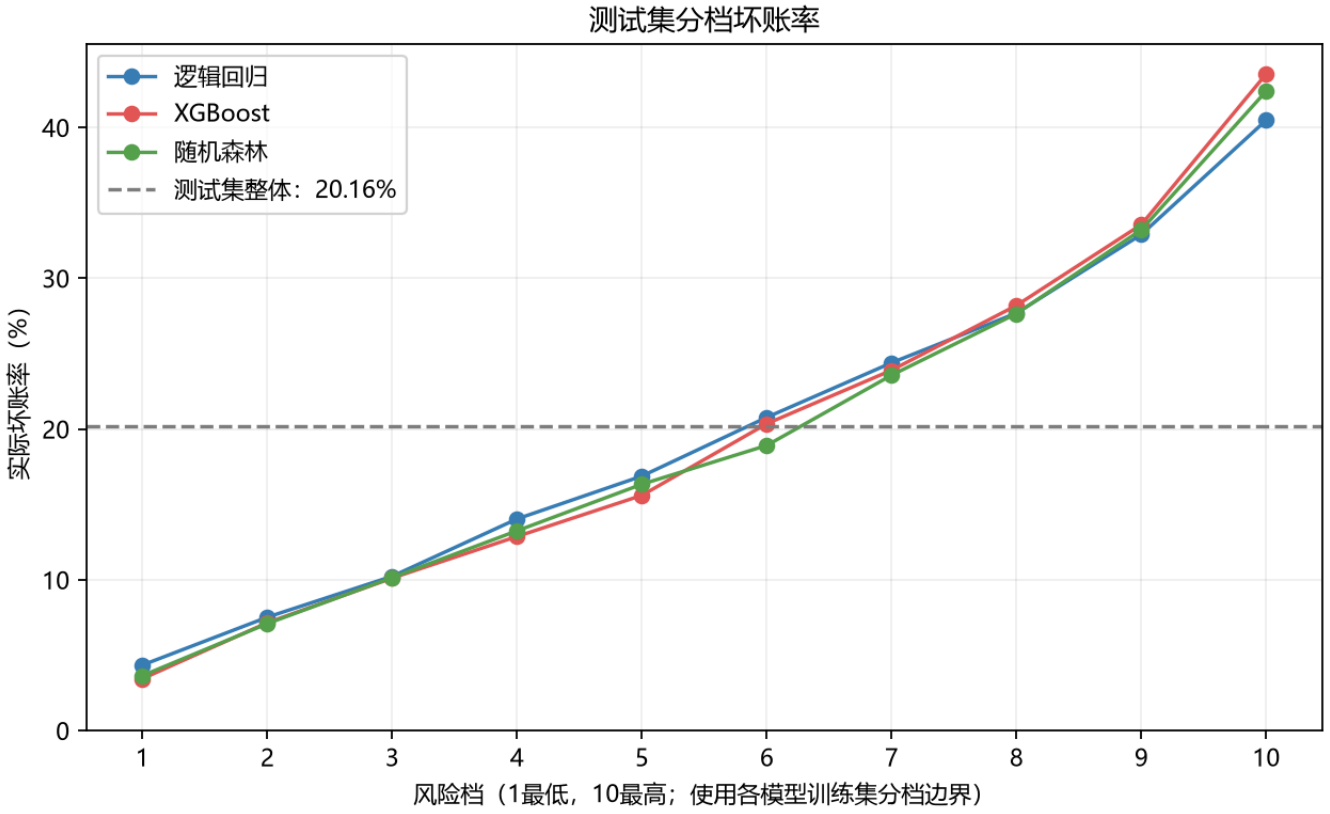
3.3 分档坏账率

各模型按自己的训练集预测概率切成 10 档，再把同样的分档边界用于测试集。第 1 档风险最低，第 10 档最高；测试集每档人数不一定相等，不同模型同一档也不一定是同一批客户。

模型	最低风险档坏账率	最高风险档坏账率	最高风险档样本数
逻辑回归	4.34%	40.48%	7,796
XGBoost	3.44%	43.54%	7,783
随机森林	3.64%	42.41%	7,704

三个模型的坏账率都随风险档上升，说明都能做出风险分层。XGBoost 的最低档坏账率更低、最高档更高，高低风险客户分得更开。

测试集整体坏账率为 **20.16%**，可作为图中的参考线。



4. 选型结论

XGBoost 在验证集 AUC、测试集 AUC 和测试 KS 上都领先，分档坏账率也支持这个结论，适合继续做风险排序和阈值优化。

模型	优点	不足
XGBoost	能学习非线性和交互，本次 AUC、KS 和风险分层最好	参数和解释更复杂，可能过拟合
逻辑回归	系数方向容易说明	分度低
随机森林	处理非线性	预测和解释成本高